

Západočeská univerzita v Plzni

Fakulta aplikovaných věd

**Semestrální práce na  
rozpoznání chirurgických řezů a  
stehů**

KKY/ZDO

25. května 2023

Martin Stránský, Dominik Poch

# Obsah

<b>1</b>	<b>Úvod</b>	<b>2</b>
<b>2</b>	<b>Segmentace</b>	<b>2</b>
<b>3</b>	<b>Popis objektů</b>	<b>3</b>
<b>4</b>	<b>Klasifikace</b>	<b>4</b>
<b>5</b>	<b>Zpracování dat a výsledek nastavování klasifikátoru</b>	<b>4</b>
5.1	Špatně klasifikované obrázky . . . . .	5
<b>6</b>	<b>Výstup</b>	<b>5</b>
<b>7</b>	<b>Závěr</b>	<b>6</b>

# 1 Úvod

Semestrální práci pro hodnocení kvality chirurgických řezů a stehů jsme rozdělili do čtyř částí. V první fázi provádíme segmentaci objektů z obrazu tak, abychom je byly schopni rozumně popsat. Popis řezů a stehů je obsažen v druhé části semestrální práce. Hlavním pilířem segmentace a popisu se stala v naší práci skeletonizace. Podle vlastností, které získáme z vysegmentovaného skeletu, objekty následně rozdělujeme do dvou zmíněných tříd pomocí klasifikace. Na závěr z popisu vyvodíme hodnocení stehů na vstupním obrázku.

## 2 Segmentace

Před segmentací se vstupní obrázek nejprve předzpracuje. Vstup převedeme do šedotónu, abychom s ním mohli dále pracovat. Přímé použití segmentace na šedotónový obraz nám neposkytovalo dostatečně konzistentní výsledky pro obrázky s různě tmavým pozadím. Pro korekci rozdílu mezi intenzitou pozadí a stehy, škálujeme kontrast obrázku do rozsahu 0-255. Výsledek této operace lze vidět na Obrázku 1. Díky tomu se nám snadněji volily prahy u segmentace.

Pro segmentování chirurgických řezů a stehů používáme segmentaci narůstáním oblastí pomocí Sobelova hranového operátoru. Pro rozrůstání oblastí se používá Watershed algoritmus s markery rozdělenými do dvou skupin

- $\text{pixels} < 100 = 1$
- $\text{pixels} > 150 = 2$

Toto rozdělení jsme získali metodou pokus omyl a osvědčilo se nám na několika zkušebním obrázcích, jak lze vidět na Obrázku 2.

Po segmentaci se převede obraz z šedotónu do binární formy, aby bylo možné na obrázek použít matematickou morfologii. Abychom odstranili malé osamocené body, používáme erozi se čtvercovým strukturním elementem o



Obrázek 1: Šedotón se zvýšeným kontrastem



Obrázek 2: Segmentace




Obrázek 3: Morfologie

velikosti 4x4. Často se stane, že se steh nebo řez rozpojí. Proto zaplňujeme vytvořené díry následnou dilatací s větším strukturním elementem. Prozatím se nám osvědčila velikost 6x6. Po použití morfologických operací získáme Obrázek 3. Zvětšení objektu nám příliš nevadí, protože na vysegmentovaný obraz používáme skeletonizaci, jejíž výsledek na Obrázku 4 se v dalším kroku používá k popisu objektů.

### 3 Popis objektů

Volba skeletů souvisí a má (podle nás) výhody právě v souvislosti s potřebným popisem výsledných objektů – sledované objekty mají totiž poměrně jasné vlastnosti a uvažované parametry k popisu jsou do značné míry v překryvu s těmi, které jsou obsaženy ve skeletech. K popisu provedených úkonů je potřebná znalost těchto parametrů: délka provedeného řezu či řezů a délka jednotlivých stehů, šířka téhož a případně jejich vzájemné poměry. Zároveň jednotlivé uzly v rámci skeletu jsou dalším vhodným popisným parametrem, lze z nich odvodit i úhel mezi řezy a stehy. Zároveň lze z informací ze skeletu získat potřebné informace pro konstrukci úseček/křivek obdobných těm v rámci ruční klasifikace.



Obrázek 4: Skelet



Obrázek 5: Výsledek algoritmu skan

Jelikož je získání popisu skeletu (a jeho jednotlivých subkomponent) samo o sobě bez dalších nástrojů náročný proces, provedli jsme rešerši dostupných nástrojů a rozhodli se z výsledků využít knihovnu skan<sup>1</sup>. Všechny námi uvedené příznaky/metriky nám tento nástroj poskytne – a mnohé další. Vyobrazení segmentů, která knihovna poskytne je k dispozici v Obrázku 5.

## 4 Klasifikace

Pro klasifikaci segmentů skeletu mezi řezy a stehy jsme využili Support Vector Machine. Pro zadaný problém se jedná o vhodný klasifikátor, jelikož rozděljuje objekty právě do dvou tříd a podává obecně dobré výsledky. Z kapitoly 3 jsme pro příznakový vektor v konečném stavu využili pouze normovaný jednotkový vektor vytvořený mezi počátečním a koncovým bodem daného segmentu kostry (s ohledem na různé škálování/přiblížení dostupných dat se tento přístup ukázal pro přesnost rozpoznávání jako klíčový).

V rámci ladění se nám s daným popisem podařilo dosáhnout až 98% přesnosti na trénovacích datech (s ohledem na počáteční výsledky si toto dovoluujeme prohlásit za až nečekaně uspokojujivý výsledek).


## 5 Zpracování dat a výsledek nastavování klasifikátoru

Pro `branch_types` a pro části skeletu, které klasifikátor označil za **-1** (incisions), jsou zpracovány počáteční a koncové body získané z `branch_data` (popis jednotlivých „výběžků“ z kostry. Počáteční a koncové body těchto jednotlivých částí skeletu jsou uloženy k dalšímu zpracování. Konkrétně jsou následně nalezeny průsečíky mezi dvojicemi řez/steh a posléze je určen i úhel pro příslušnou dvojici.


<sup>1</sup>[https://skeleton-analysis.org/stable/getting\\_started/getting\\_started.html](https://skeleton-analysis.org/stable/getting_started/getting_started.html)

## 5.1 Špatně klasifikované obrázky

V datasetu se vyskytují jednotky obrázků, které se výrazně typově liší od ostatních. Principiálně by mělo být možné je určit a upravit výše použitý postup i pro ně, leč s ohledem na zvolený stranový popis by to znamenalo novou třídu dat a vedlo na jiný popis a tím nutnost vymyslet další klasifikátor nebo zřetězit více SVM za sebou. Protože se nám nepodařilo vymyslet konzistentní kritérium, jak takovýto odlišný typ obrázku odhalit, ponecháváme výsledné řešení v prezentovaném stavu s vědomím existence tohoto jevu. Výsledná skeletizace potom dopadne takto:



(a) Grayscale



(b) Skelet

Obrázek 6: Špatně klasifikované obrázek, nejhorší případ

## 6 Výstup

Tímto jsou získána všechna potřebná data a zbývá data uložit k dalšímu použití. Výsledky ukládáme do předepsaného formátu do JSON-souboru. S ohledem na rozsah datasetu zapisujeme vše s pomocí standardního json modulu s využitím dump. Pro větší rozsah by bylo vhodnější použít knihovnu json-stream, která umožňuje generovat json iterativně ze streamu, implementace by ale byla náročnější a pro potřebný rozsah nadbytečná, dat není tolik, aby se nevešly soubory do paměti v jednom bloku.

## 7 Závěr

I přes poměrně malý dataset a citelně suboptimální kvalitu obrazových dat se nám podařilo s podporou dostupných nástrojů a knihoven v Pythonu vytvořit řešení, které pro „standardní“ (co do přítomnosti v datasetu) typy řezů a jejich šití poskytuje typicky poměrně rozumnou anotaci.

Možným vylepšením pro trénovací proces, s velkým otazníkem možná vedoucí k lepším trénovacím výsledkům, by mohlo být důkladnější využití dostupných anotovaných dat: S využitím znalosti průsečíků v datech by bylo možné získat jemnější dělení (rozdělit jednotlivé segmenty), čímž by celkové množství trénovacích dat mohlo vzrůst – jinými slovy trénovat na částech celých řezů a jednotlivých stezích v rámci obrázku namísto trénování na celém obrázku. Tímto by zároveň mělo být jednodušší dodat „jiné“ typy řezů nebo by mohlo být s dalšími nástroji možné ohodnotit jednotlivé segmenty v rámci daného obrázku (například co do kvality provedení).